

데이터마이닝 최종 보고서

아파트 커뮤니티 시설 공급 패턴 분석

수요 간접 예측 — 서울시 신축 아파트 1,123개 단지 대상

빅데이터학과/ 양세미 (2024720536)

GitHub: <https://github.com/semarie-y/aptcommunity>

Streamlit: <https://apt-community-analysis.streamlit.app/>



목차 Contents

01

프로젝트 개요

연구 목적, 가설 Q1~Q4, 분석 기준

02

데이터 수집 및 전처리

4개 소스 수집 · 텍스트 분류 · 결합
파이프라인

03

탐색적 데이터 분석 (EDA)

시설 보유율 · 변수 분포 · 상관관계

04

분류모델 학습

모델 설계 · 5-Fold CV · 성능 비교

05

SHAP 변수 기여도 분석

시설별 Top3 변수 · 방향성 해석

06

최종 가설 검증 및 결론

Q1~Q4 판정 · 인사이트 · 연구 한계 · 향후
과제

1. 프로젝트 개요



연구 목표

서울 신축 아파트 커뮤니티
공급 패턴 분석 및 수요 간접 예측



연구 전제

공급 패턴을 수요의 간접 지표로 활용



연구 한계

실제 이용 수요와 구분함
(법정 기준·브랜드 전략 등 복합 요인)

[표 1] 연구 질문과 최종 판정

Q1. 1인가구비율▲ → 공유오피스 공급▲?

기각

Q2. 아동비율▲ → 키즈시설 공급▲?

지지

Q3. 고령비율▲ → 시니어시설 공급▲?

기각/재해석

Q4. 주변 상권▲ → 단지 내 유사 시설▼?

부분 지지

[표 2] 최종 분석 기준 요약

분석 단지	1,123개 (단지키 중복 0개)
분석 범위	서울 25개 구
모델 타겟	6개 커뮤니티 시설 (운동시설, 교육·학습시설, 키즈시설, 시니어시설, 공유오피스·회의, 라운지·휴게)
최종 피처	18개 (인구 7 + 상권 6 + 지역 5)
평가 지표	보유 클래스 F1 (주 지표)

2. 데이터 수집 및 전처리

■ 데이터 소스 수집



■ 전처리 파이프라인



■ 결측 처리 결과 요약

최종 단지 수	단지키 중복	인구 직접 매칭	상권 직접 매칭	최종 결측
1,123개	0개	1,065 / 1,123개	1,123 / 1,123개	0개

2. 데이터 수집 및 전처리

■ 비정형 텍스트 분류

- 키워드 사전 구축 (예: '피트니스', '작은도서관', '어르신' 등)
- 수동 검증 정확도: 98.0% (49/50 샘플)
- 오분류('용역원 휴게실') 제외 키워드 추가 보완

■ 단지 단위 집계



[다중공선성 대응]

인구/세대 변수 간 다중공선성 존재. 원변수 가설 검증 위해 PCA 미적용(원변수 유지). SHAP 중요도로 모델 해석 보완.

■ 데이터 결합 및 결측

- 인구·세대: 미매칭분 구/서울 평균 대체 (100% 결합)
- 상권: 법정동 직접 매칭 (100% 결합)

모델 컬럼 결측치: 0개 확정

■ 최종 모델 피쳐 (총 18개 확정)

- 인구·세대 (7개): 아동, 고령, 1인~3인가구 등
- 상권 (6개): 카페(log), 헬스장(log) 등
- 지역 통제 (5개): 권역, 구 단위



3. 탐색적 데이터 분석 (EDA)

시설별 보유율 (n=1,123)

시설 유형	보유	미보유	보유율
키즈시설 🧒	621	502	55.3%
시니어시설 👴	510	613	45.4%
운동시설 🏃	377	746	33.6%
교육·학습시설 📖	351	772	31.3%
공유오피스·회의 📁	197	926	17.5%
라운지·휴게 🪑	176	947	15.7%

인구·세대 변수 기초 통계

변수	평균	중앙값	최솟값	최댓값
아동비율 🧒	5.45%	5.19%	1.22%	13.86%
고령비율 👴	26.79%	26.95%	7.45%	41.67%
청년비율 🧑	13.60%	12.46%	7.25%	44.07%
1인가구비율 🏠	41.75%	41.13%	15.47%	82.94%
3인이상비율 👨‍👩‍👧	35.19%	34.41%	6.40%	62.28%






3. 탐색적 데이터 분석 (EDA) — 상관관계 및 가설 예비검증

■ Q1~Q3 예비검증 결과

가설	관계	상관계수	보유-미보유 평균차	예비 해석
Q1	1인가구비율 → 공유오피스·회의	+0.004	+0.11%p	거의 무관 — 단변량으로 지지 어려움
Q2	아동비율 → 키즈시설	+0.144	+0.47%p	가설 방향 지지 — 가장 뚜렷한 신호
Q3	고령비율 → 시니어시설	-0.083	-0.81%p	가설 반박 — 신축 단지 지리적 불일치

■ 상관관계 시각화



4. 분류모델 학습

■ 모델 설계 요약

항목	내용
타겟	6개 시설 유형 각각 이진 분류 (보유=1, 미보유=0)
피쳐	18개: 인구·세대 7 + 상권 log 6 + 지역 통제 5
교차검증	5-Fold Stratified Cross Validation
비교 모델	Dummy Majority Baseline / Logistic Regression / Random Forest
클래스 불균형	class_weight = balanced
주 평가 지표	보유 클래스 F1 (Positive-class F1)
보조 지표	Macro F1, Balanced Accuracy, Precision, Recall

▲ 키즈시설 주의 사항

보유율 55.3%로 높아 Majority Baseline 보유F1 = 0.712

→ 보유F1 단독 해석 금지

→ Macro F1 + Balanced Accuracy 병행 해석 필요

■ 최종 모델 성능 요약

시설 유형	채택 모델	보유F1	MacroF1	판정
운동시설 🏊	Logistic Reg.	0.423	0.526	유의미
교육·학습시설 📖	Logistic Reg.	0.424	0.545	유의미
키즈시설 🧒	Random Forest	0.580	0.547	재검토
시니어시설 👴	Random Forest	0.534	0.565	유의미
공유오피스·회의 📁	Logistic Reg.	0.295	0.467	유의미
라운지·휴게 ☕	Random Forest	0.289	0.544	유의미

■ 상권 변수 기초 통계

변수	평균	중앙값	최댓값
카페수 ☕	118.5	81.0	570
헬스장수 🏋️	26.7	18.0	135
학원수 📖	124.5	82.0	1,240
독서실수 📚	17.6	12.0	163

5. SHAP 변수 기여도 분석

■ 기존 접근의 한계



다중공선성으로 인한 로지스틱 회귀 계수 불신뢰

1인가구비율 ↔ 3인이상비율 상관계수 -0.96 등 구조적 다중공선성 존재.
→ 회귀 계수가 변수 실제 영향력을 왜곡하여 가설 검증에 직접 사용 불가.



Random Forest 내부 블랙박스 문제

RF는 예측 성능은 우수하나 개별 피쳐 기여를 단순 feature importance로는 방향성(보유↑ vs 미보유↑)까지 파악할 수 없음.

■ SHAP 채택 이유

01

모델 무관 공정한 기여 분배

LR·RF 두 모델에 각각 LinearExplainer / TreeExplainer를 적용,
단일 기준으로 피쳐 중요도를 비교 가능.

02

기여 방향성 파악

SHAP 값의 부호(+/-)로 '변수↑ → 보유↑'인지 '보유↓'인지 구분.
가설 검증에서 상관계수를 대체하는 핵심 근거로 활용.

03

다중공선성 속에서도 안정적 해석

공선성 변수를 묶어 전체 기여를 함께 해석 가능.
PCA 미적용으로 원변수 가설 Q1~Q4를 유지하면서 해석력 확보.

5. SHAP 변수 기여도 분석

다변량 SHAP기반 모델 핵심 기여 피쳐

시설 유형	1순위 피쳐	2순위 피쳐	3순위 피쳐
운동시설 🏃	카페수(log)	서남권	2인가구비율
교육·학습시설 📖	아동비율	학원수(log)	헬스장수(log)
키즈시설 🧒	아동비율	2인가구비율	사우나수(log)
시니어시설 👴	아동비율	2인가구비율	3인이상비율
공유오피스·회의 📁	카페수(log)	사우나수(log)	동북권
라운지·휴게 ☕	3인이상비율	1인가구비율	아동비율



6. 최종 가설 검증 및 결론

▪ Q1~Q4 최종 가설 검증 결론표

가설	SHAP / 다변량 근거	상세 내용	최종 판정
Q1. 1인가구▲ → 공유오피스▲	1인가구비율 SHAP 12위, 중요도 0.100	SHAP 12위, 인구 통계적 영향 미미함	❌ 기각
Q2. 아동비율▲ → 키즈시설▲	아동비율 SHAP 1위, 중요도 0.0375	단변량 상관성 및 SHAP 중요도 모두 1위	✅ 지지
Q3. 고령비율▲ → 시니어시설▲	고령비율 SHAP 9위, 미보유 방향	음의 상관. 지리적 불일치 발생	⚠️ 기각 / 재해석
Q4. 외부상권▲ → 유사시설▼	카페수 SHAP 1위, 학원수 2위, 헬스장 11위	카페, 학원, 헬스장 등 상권 유형별로 대체/보완 효과가 혼재함	🕒 부분 지지

▪ Q4 방향 분석 상세

후보	관계	상관계수(log)	해석
Q4-1	카페수 → 공유오피스·회의	+0.0483	보완/동반 가능성
Q4-2	헬스장수 → 운동시설	-0.0122	약한 대체 가능성
Q4-3	학원수 → 교육·학습시설	+0.0138	약함/불명확
Q4-4	독서실수 → 교육·학습시설	-0.0139	약함/불명확

6. 최종 가설 검증 및 결론

■ 핵심 인사이트



명확한 수요 시그널

아동비율은 키즈시설 공급을 예측하는 가장 강력하고 일관된 지표로 확인됨 (Q2 완벽 지지).



지리적 미스매치 발견

고령 인구 밀집지와 신축 시니어시설 공급 지역 간의 지리적 불일치 현상 시사. 단순 인구 비례 공급이 아님.



상권의 복합적 역할

외부 상권은 커뮤니티와 '대체(헬스장)' 및 '보완(카페)' 관계를 동시에 가짐.



선택형 시설의 한계

공유오피스, 라운지 등은 인구 통계만으로 설명 불가. 상권 밀집도 및 권역 등 지역적 특성이 필수적으로 고려되어야 함.

6. 최종 가설 검증 및 결론



연구 한계

■ 데이터 제약

'실제 이용 수요'가 아닌 건축 인허가상 '공급 데이터'의 한계.

■ 비정형 텍스트 한계

키워드 기반 분류 시 신조어 및 외래어 완벽 포착 어려움.

■ 다중공선성

인구·세대 비율 간 구조적 공선성 존재 (로지스틱 계수 해석 제한).

■ 공간 해상도

상권 변수가 법정동 단위 카운트로, 실제 도보 접근성 미반영.



향후 과제

■ 변수 확장

단지 고유 특성(규모, 세대수, 브랜드, 분양가) 모델 추가.

■ 공간 데이터 정교화

반경 기반(500m~1km) 공간 버퍼로 상권 업소 재집계.

■ 일반화 검증

동 단위 데이터 누수 방지를 위한 GroupKFold 교차검증 적용.

■ 해석 고도화

SHAP Dependence Plot 추가를 통한 변수 방향성 정밀 해석.

부록) SHAP 분석 기법 개요

SHAP이란?

게임 이론의 Shapley Value를 ML 모델 해석에 적용한 기법.
각 피처(변수)가 예측값에 기여한 정도를 정량화·시각화.

핵심 수식 개념

$$f(x) = E[f(x)] + \sum \phi_i$$

$f(x)$: 모델 예측값 $E[f(x)]$: 기대값(평균) ϕ_i : i 번째 피처의 SHAP 기여값

SHAP의 3가지 핵심 특성

- ✓ **Local Accuracy:** 예측값을 피처 기여의 합으로 정확히 분해
- ⚖ **Consistency:** 모델이 바뀌어도 기여도 방향성 일관성 유지
- 🎯 **Missingness:** 피처값 = 0이면 SHAP 기여도도 0으로 처리

이렇게 이해하세요 — 쉬운 설명

팀 프로젝트 기여도



A·B·C 세 팀원이 함께 100점을 받았을 때,
각자 몇 점씩 기여했는지 계산하는 것과 같습니다.
SHAP은 변수(팀원)별 기여를 공정하게 나눕니다.

왜 이 예측이 나왔나요?



모델이 '키즈시설 보유'로 예측했을 때,
아동비율(+0.4), 카페수(+0.2), 고령비율(-0.1) 식으로
각 변수의 기여량을 숫자로 설명해 줍니다.

방향도 알려줍니다



단순 중요도(절댓값)뿐 아니라
+ 이면 '보유 확률을 높임',
- 이면 '보유 확률을 낮춤'까지 파악할 수 있습니다.

어떤 모델에도 사용 가능



로지스틱 회귀, 랜덤 포레스트, 딥러닝 등
모델 종류에 상관없이 동일한 기준으로
피처 기여도를 비교할 수 있습니다.